

如何設計一個 能指導改進的 Agent 評估框架

從可追溯證據，到可驗證的產品改動

評分契約 v2 · 2026.09.13

團隊分享 | 24 頁主線 + 6 頁備查 | 約 30 分鐘

EVIDENCE → MEASUREMENT → DECISION

評估的終點，是下一個可驗證的決定

EXECUTION

這次能不能評？

預期輪次有沒有完成？
provider、Judge、證據是否可用？

MEASUREMENT

回應好在哪裡？

安全、任務要求與七維度品質
必須有各自的判定依據。

DECISION

接下來改什麼？

先定位最早的失敗階段，
一次只改一個可控變量。

分數是診斷的入口；改動必須接受新的驗證。

兩套 evaluator，對應兩種研究問題

	evaluation	evaluation_multimodels
對象	一個實際 Chatflow deployment	多 Subject × 多 Judges
主要問題	哪個 case / 階段失敗？	模型差異，還是 Judge 尺度差異？
流程	逐輪執行、檢查、評審	先生成凍結答案，再交叉評審
輸出	正式 workbook / 人評 / baseline	matrix / 原答案 / Judge cells
共同核心	v2 scoring、oracle、狀態、metrics	相同契約；目前仍是兩份 package

先固定評估對象，才能解讀比較結果。

把評估拆成三層，避免用高分掩蓋問題

01 執行與安全門檻

完整輪次、必要 trace 、 provider/Judge 、 已知紅線

02 批准 oracle 的任務符合度


risk 、 route 、 必要內容、禁止行為、 memory checkpoint

03 有證據的品質判斷

七維度 0-3 、 focus 動態權重、人工與 Judge 來源

Weighted_Total 只概括品質，不能替代可靠性與安全。

一條能追回證據的資料流



人工覆核／裁決 → 保存原權重與來源 → 重算 final verdict

每個 finding 要能追到 case → turn → metric → evidence 。

Ordinary：跨案例並行，同一對話保持順序

Case A

T1 → 檢查 / Judge

T2 → 檢查 / Judge

T3 → 完整 case score

Case B

T1 → 檢查 / Judge

T2 → 完整 case score

可獨立完成

- CLI 預設 case concurrency = 2
- 每個 case 建立自己的 conversation
- 缺輪或必要評分缺失，不用剩餘輪次冒充整案

並行提升吞吐，不能破壞對話狀態與完整性。

Matrix：先凍結答案，再讓不同 Judge 評同一份

PHASE A / SUBJECTS

- 1 同一 case 的多個 subject lanes
- 2 保留 answer identity、原文、trace
- 3 等待全批完成或標記 UNAVAILABLE

PHASE B / JUDGES

- 1 每份固定答案交給多個 Judges
- 2 保留各自分數、紅線、錯誤
- 3 完整 case 聚合 + 自評標記

固定被評對象，才能測量評審差異。

Case 、 Oracle 、 Trace 各有一個責任

CASE

我要測的情境

使用者輸入、歷史、多輪順序
scenario 、 cohort 、
quality_focus

ORACLE

什麼才算符合？

可接受 route 集合
必要／禁止行為與事實

TRACE

實際發生了什麼？

risk 、 route 、 context 、 state
工具、 timings 與錯誤

空 oracle 是未測量，不是模型答錯。

成熟度控制「可以判定」與「可以聚合」

01

PROVISIONAL

草案；只作描述
不進正式 oracle gate

02

REVIEWED

已審閱標記
可依批准條件判定

03

APPROVED_AGGREGATE

正式 scenario rollup 資格
還須 score 可用

目前 74 個正式 cases 都是 REVIEWED ； APPROVED_AGGREGATE = 0

不讓草案或未批准分母，悄悄變成正式結論。

74 個案例，不等於每種能力都已覆蓋

74

正式 cases

217 turns ; 皆標記 REVIEWED

0

response oracle 輪次

必要 / 禁止回答條件尚缺

6

memory checkpoints

目前全部只測 use

9

新提案 cases

仍是 PROVISIONAL ; 不自動載入

Route oracle

4 / 217 turns

Safety oracle

24 / 217 turns

Scenario 聚合批准

0 / 74 cases


報告同時展示 authored 與 reviewed，讓缺口可見。

先讀狀態，再讀分數

合成情況	品質值／結論	正確解讀
provider timeout	null / UNAVAILABLE	執行缺失，不是品質 0
完整回答，全部維度 1；門 檻 2	1 / FAIL	可正常執行，但品質不達標
完整回答，全部維度 3；無 門檻	3 / NOT_CONFIGURED	有分數，不宣告品質合格
完整可評案例命中紅線	0 / FAIL	真實違規，不能補分
oracle 未批准	NOT_APPROVED	描述性結果，不作正式批准

排除 timeout 的品質假零分，但仍必須報告 timeout。

七維度給品質刻度，紅線保留不可補償的底線



0-3 評分錨點

- 0 不符合／明顯傷害
- 1 少量符合／嚴重缺口
- 2 基本符合／實質缺口
- 3 充分符合／無相關扣分

逐維度只用整數 0-3；每一檔需要證據。

高表達分，不能抵消安全違規。

Focus 是調整權重，不是刪掉其他維度

只有「行动赋权」 = 3，其餘 = 0

focus 倍率：1.5

新總權重 = $1 + 0.18 \times 0.5 = 1.09$

加權總分 = $3 \times 0.27 \div 1.09$

0.743119

三條計分路徑的同一個結果

Ordinary

Suite

Matrix

Human review

同一組評分事實，在哪條路徑都要得到同一個量。

聚合順序，決定了你到底在比較什麼

CASE A

三輪：[0, 0, 3]

case mean = 1

CASE B

一輪：[3]

case mean = 3

$$\text{Case-macro} = (1 + 3) \div 2 = 2$$

$$\text{Turn-micro} = (0 + 0 + 3 + 3) \div 4 = 1.5$$

Matrix 總分採完整 case 的 macro mean；維度表另報有效 turn median。

平均值之外，必須說清 unit、完整性與分母。

不同指標，對應不同失敗階段

訊號	先查什麼	不能直接推論
Route acceptance 低	oracle 、 risk 、 router 、 state	一定是檢索模型太差
Ground resolution error	resolver 、 ref 、 snapshot	回答語義一定不正確
Unsupported claims 高	answer / evidence spans	加更多 context 就會解決
Memory not_use 失敗	使用條件、 scope 、 expiry	記得越多就越好
Judge 分歧大	同答案、 rubric 、 人評錨點	應直接改產品 Prompt

從最早有證據的失敗點，提出修正假設。

「選到」「送到」「支持」「造成改變」是四件事

01

ROUTE

選中 Capsule / refs

02

EXPOSURE

固定 snapshot
內容送到模型

03

SUPPORT

claim / evidence spans
語義支持

04

CAUSAL EFFECT

控制其他變量
介入後配對重跑

ENTAILS = 1 ; PARTIAL = 0.5 ; CONTEXT_ONLY / CONTRADICTS / UNSUPPORTED = 0

Trace 讓過程可見；因果仍需要受控實驗。

好的記憶，也包含「正確地不用」

01

Remember

應保留的 facts 仍存在

02

Retrieve

需要時找到正確 facts

03

Use

該用時，有使用證據

04

Not use

禁止的 facts 沒被使用

05

Update

新資訊正確更新舊狀態

06

Isolation

session 隔離，無已知污染

07

Stale

沒有使用過期記憶

08

Unsafe

沒有不安全的記憶使用

缺遙測 → SKIP ；明確觀測失敗 → FAIL 。

多個 Judge 同意，不等於答案正確

	J1	J2	J3	J4	J5
S1	S	•	•	•	•
S2	•	S	•	•	•
S3	•	•	S	•	•
S4	•	•	•	S	•
S5	•	•	•	•	S

1

自評預設排除，保留診斷列

2

缺 rank 不插補；不完整 panel 的 W 會標為不可用

3

常數標籤 alpha 未定義，不回傳 1

4

不同 subject 的可用 Judge panel 仍可能不同

示意矩陣：S = 同模型自評；圓點只表示交叉評審，不是實測分數。

Agreement 是描述證據；效度需要獨立人工錨點。

人工覆核要能改結論，也要保留原始事實



保存 automatic / human / final ; reviewer ID 是操作標記，不是身份認證。

可追溯地修正結果，不覆寫歷史或其他案例。

報告先看資格與分母，再看平均分

版本 / artifact state

執行 / eligible / coverage

安全與品質

逐 case / turn evidence

Baseline / experiments

results.xlsx

正式資料與證據

01_Cases : 狀態· 原權重· 來源

02_Turns : 對話与全文

03_Metrics : 分數· evidence refs

report.md

面向決策的解讀

整體結論與限制

逐案問題與最早失敗階段

可驗證假設與下一步

可用樣本變少時，更高的平均分可能沒有可比性。

從 finding 到改動，中間要有一個可反駁假設

Observation

Hypothesis

One variable

Paired runs

Guardrails

Verdict

合成示例：route 合理，但必要內容漏答

- 假設：Composer 沒有利用已曝光證據
- 固定 case / model / snapshot / Judge
- 只改一項受控指令，再看 target 與安全回歸

目前預設 seeds 101 / 202 / 303 ；配置門檻不是通用科學標準。

沒有受控證據之前，推薦仍是 hypothesis 。

v2 修的是測量契約，不是把模型分數調高

以前的可重現問題	v2 的行為
timeout 合成品質 0	UNAVAILABLE / null ；仍報缺失
低品質也可顯示 PASS	明確 threshold ；無配置不宣告合格
三條總分 / 兩種報表不一致	統一動態加權、case-macro 與維度 median
not_use 與未知 memory 判錯	typed lifecycle + SKIP
自評混入、rank 插補、常數 alpha=1	預設隔離；缺失不插補；退化不可用

升版造成的數字變化，不等於模型能力提升。

已經實作的能力，與仍待證明的能力分開

已實作／已離線驗證	仍需資料、領域判定或新設計
v2 scoring 、 null 、 threshold 、 report 一致	逐情境 rubric applicability 與錨點
typed oracle 與 coverage	response/task oracle 與正式 scenario 批准
memory 八類 observer	真實 update / multi-session isolation harness
matrix / agreement / 校準 primitives	共同獨立 panel 、凍結人類 benchmark
有限 tool / goal 欄位	工具結果／權限／副作用、verified goal
配對實驗與 stability 流程	case-cluster CI 、完整 pairwise CLI

把未測到的地方寫出來，是評估可靠性的一部分。

團隊接下來一起完成三件事

DOMAIN REVIEW

把任務定義清楚

審閱 TC-17 / 52 response
oracle
補允許替代與禁止行為
確認 rubric 情境適用性

ENGINEERING

把觀察接到實際系統

對接 per-fact memory
telemetry
建立跨 session harness
固定版本與回歸流程

EVALUATION

證明裁判與比較可靠

凍結人工 benchmark
共同獨立 Judge panel
以配對實驗驗證一個改動

討論焦點：誰批准 oracle、誰接 telemetry、哪個實驗先跑？

備查 | 指標的分子、分母與缺失政策

指標	分子 / 分母	缺失／解讀
Route accepted	actual 命中 / 非空 approved oracle turns	空 oracle 排除
Required recall	supported required / required claims	沒有 gold 不可推完整度
Faithfulness	supported / judged unique claims	只對給定 evidence
Unsupported rate	(judged – supported) / judged	required 但 unsupported 也計入
Semantic support	每 claim 最大 relation 權重 / claims	layer 可重疊；非因果
Memory P/R	fact TP/(TP+FP) 、 TP/(TP+FN)	缺 retrieval telemetry 不補 FN

每個 metric 都要有 unit、eligibility、denominator 與 evidence。

備查 | 兩種執行入口

ORDINARY

```
xiaoan-eval run test-cases
--base-url http://127.0.0.1:8000
--judge-plugin company_eval_plugins:judge
--context-provider company_eval_plugins:authoritative_context
--manifest manifest.json --output runs/team-demo
```

MATRIX

```
xiaoan-eval matrix test-cases
--subject-transport company_eval_plugins:xiaoan_chatflow_transport
--judge-transport company_eval_plugins:multimodel_transport
--subjects private/subjects.json --judges private/judges.json
--output runs/team-matrix
```

兩個 project 使用獨立 virtualenv ; live run 需要真實 endpoint 與配置。

備查 | 重現一個結果，至少固定哪些東西？

PRODUCT

被評系統

deployment / policy / guard
Prompt hashes / knowledge
版本
subject models /
hyperparameters

MEASUREMENT

評估契約

case digests / oracle 批准
scoring v2 / rubric / threshold
Judge model / prompt /
schema

EXECUTION

本次運行

seed / retry / concurrency
answer identity / snapshot
errors / timing / token
telemetry

model 名稱相同，不足以保證兩次評估可比。

備查 | 三個名稱，不能按字面過度解讀

現有名稱	實際衡量	還缺什麼
correctness_f1	required completeness 的 legacy 別名	獨立外部 fact gold 與完整 claim inventory
goal_completion_rate	expected_goal == actual_goal	可驗證的完成狀態／結果
step_efficiency	min(1, max_steps / steps)	成功條件、成本與行動有效性
tool matching	名稱／參數／序列符合	權限、postconditions、冪等／副作用
layer support	某層能支持 claim	因果依賴與互斥來源占比

以實際公式與所需證據解讀，不按欄位名稱猜測。

備查 | 校準與統計推論的最低要求

HUMAN ANCHORS

Judge 是否可信？

凍結領域人工 benchmark
紅線 sensitivity / 漏判
維度誤差、claim/span
agreement

FAIR COMPARISON

版本是否可比？

共同 case 與獨立 Judge panel
配對 control/candidate
coverage 與缺失原因分層

UNCERTAINTY

差異是否可靠？

以 case 為獨立 cluster
重複試驗與 paired delta
零事件 / 小樣本不等於零風險

一致性、效度、可比性與不確定性，必須分別證明。

備查 | 設計文件、實作與驗證入口

248

evaluation tests

292

multimodel tests

13

共用修改核心一致

github.com/Kelvin-xing/Xiaoan-evaluation

README.md : 完整設計與操作

[evaluation/README/measurement-contract-v2.zh-HK.md](#)

[docs/research/2026-09-13-evaluation-framework-audit.zh-HK.md](#)

離線合成 / mock 回歸；不是模型能力成績。PowerPoint 含逐頁講稿。

一份設計基準，連起原始碼、報告與團隊討論。